

SOVEREIGN AI CLOUD OS

SCARLIX OS

Suverénny domáci OS pre AI cloud, coding, gaming a rodinnú zábavu

v18.8.5 – EndeavourOS Edition

99+

COMMITTS

26

TAGS

12

CI TESTS

15

GO TESTS

Aktuálny systém v18.8.5

SCARLIX OS je **bootstrap installer** — žiadne ISO. Spustí sa `bash install.sh` na čistej EndeavourOS inštalácii a za 5 fáz postaví kompletný AI stack s GPU podporou, Dockerom, a ScarliHQ dashboardom. Všetko je **fail-closed** — ak niečo zlyhá, systém to povie, nie ticho pokračuje.

TIER 1	SGLang v0.4.4-cu128 — GPU 0, RadixAttention, --disable-flashinfer (Blackwell sm_120 safe)
TIER 2	vLLM v0.8.0 — GPU 1, TP=1 (experimental, .experimental gate)
TIER 4	BeeLlama / llama.cpp — CPU offline fallback, Q4_K_M GGUF
FALLBACK	Ollama 0.5.4 — CPU tertiary, qwen2.5:3b starter model
GATEWAY	LiteLLM v1.16.19 — unified OpenAI API na :4001, dynamic config z models.yaml
DASH	ScarliHQ — Go binary, Alpine, token auth, WS ticket system, host-bridge architecture

Bezpečnostná architektúra: ScarliHQ kontajner NEMÁ docker.sock, NEMÁ nvidia runtime. Komunikuje len cez súborový bridge — zapisuje `desired-mode` do `bridge-input/` (UID 65532), root host-bridge timer (5s) číta cez **Go O_NOFOLLOW atomic reader** a vykonáva privileged operácie. Žiadny TOCTOU, žiadny symlink attack.

Mode lifecycle: `scarlix-mode ai` spustí SGLang → vLLM → BeeLlama → Ollama fallback chain + LiteLLM gateway. `scarlix-mode stop` zastaví všetko vrátane LiteLLM. Game/Creative/TV módy zastavia AI + uvoľnia VRAM. Healthcheck kontroluje všetky kontajnery + API endpoints.

Čo v18.8.5 prináša

OBLASŤ	RIEŠENIE
CI Pipeline	12 integration testov, Go unit testy, shellcheck, YAML validácia, Docker build, WS lifecycle test, LiteLLM E2E routing + fallback test
LiteLLM Dynamic	generate-litellm-config.sh číta models.yaml → generuje config.yaml pri každom AI štarte. Model-agnostic gateway.
SGLang Tuning	context_length, chunked_prefill_size, max_running_requests z models.yaml → .env → compose. Konfigurovateľné bez zmeny image.
Image Pinning	Všetky Docker images pinned: SGLang v0.4.4-cu128, vLLM v0.8.0, Ollama 0.5.4, llama.cpp digest, LiteLLM main-v1.16.19
Self-Healing	healthcheck_and_restart() kontroluje + opravuje aj LiteLLM gateway. wait_for_healthy v recreate path s API probe.
Backup	restic init kontroluje config file (nielen dir), BACKUP_STATUS tracking, RESTIC_PASSWORD check, early return on init fail
Reproducibility	MusicGen requirements.lock, Video constraints.txt, Wan2GP git commit pin, CI artifact reuse medzi jobmi

CI GREEN

FAIL-CLOSED

REPRODUCIBLE

SELF-HEALING

ScaRgeN Visions 1-10

Pôvodných 10 vízií pre SCARLIX OS v20+ — AI-native operacný systém, kde AI nie je aplikácia ale vrstva ako networking alebo filesystem.

VISION 01

AI-Native Kernel Scheduler

Nahradí systemd timer pre AI workload. **eBPF programy** sledujú nvidia-smi + /proc/meminfo + AI API latency. Keď GPU memory pressure stúpne, scheduler automaticky zníži --max-running-requests bez reštartu. Žiadny AI request nezaseknutý kvôli pacman -Syu.

Pre nás: zero-latency AI scheduling. Pre iných: AI workload nikdy nezaseknutý OS update.

VISION 02

Neural Model Router (NMR)

Trénujúci router ktorý sa učí latency/cost/quality tradeoff per-user. **Malý ML model** (LogisticRegression) beží na CPU. Analyzuje TTFT + tok/s + context usage a dynamicky routuje. Krátke chaty → Ollama (rýchlejšie), dlhé kontexty → SGLang (lepšie KV cache).

Pre nás: automaticky najrýchlejší backend. Pre iných: žiadne manuálne prepínanie modelov.

Homomorphic Encryption Layer

FHE (fully homomorphic encryption) vrstva medzi klient a AI inference. Requesty sú encrypted end-to-end — ani host nemôže čítať prompt obsah. Pre zdravotné otázky, finančné poradenstvo. OpenFHE alebo Concrete-ML. Optional: scarlix-mode ai --private.

Pre nás: 100% private AI pre rodinu. Pre iných: first OS s encrypted inference — GDPR-ready.

Federated Learning Mesh

Viacero SCARLIX inštalácií (doma, v chate, u kamaráta) zdieľajú **KV cache fragmenty** cez Tailscale mesh bez zdieľania modelov. Latencia klesá, privacy zostáva. 3 nodes = 3x viac KV cache kapacity bez ďalšej VRAM.

Pre nás: AI na chate rovnako rýchla ako doma. Pre iných: komunita bez cloud dependency.

Voice-First OS Shell

Whisper STT + Piper TTS integrované do shell úrovne. "Scarlix, spusti AI" nahlas. Chybové hlášky sa čítajú nahlas. Dashboard ovládaný hlasom — žiadny monitor nepotrebný pre základné operácie. Wake word: "Scarlix".

Pre nás: deti a starí rodičia môžu používať AI bez klávesnice. Pre iných: first voice-native Linux OS.

Self-Healing BTRFS Snapshots

BTRFS send/receive pre incremental AI model snapshots. Keď healthcheck zlyhá 3x po sebe, ScaRgeN automaticky rollbackne /models na funkčný snapshot + reštartuje engine. Zero-downtime recovery. Snapper pre /models subvolume.

Pre nás: žiadne manuálne opravy po update. Pre iných: self-healing OS ako Kubernetes pre kontajnery.

Quantum-Safe Authentication

Kyber/Dilithium post-quantum kryptografia. Bearer token auth nahradený PQ signatures + WebAuthn (fingerprint/FaceID). Future-proof proti quantum hrozbám. Každý rodinný člen má vlastný PQ keypair. liboqs (Open Quantum Safe).

Pre nás: 10+ rokov lifetime zabezpečené. Pre iných: first quantum-safe home OS.

Edge AI Cache (EAC)

Semantic deduplication cache — embedding similarity > 0.95 = cache hit. Rodinné otázky sa opakujú ("aký je recept na..."). Cache odpovede pri Tailscale gateway. TTS odpovede sa tiež cacheujú. Cache invalidácia pri model update (hash check).

Pre nás: instant odpoveď na opakované otázky. Pre iných: 10x nižšie GPU využitie pre rodinné použitie.

GPU Composable Fabric

Dynamic multi-GPU workload balancing. 2 GPU (RTX 5060 Ti + RTX 4060 Ti) — SGLang na GPU0 pre chat, vLLM na GPU1 pre code generation. NMR posielala GPU affinity s requestom. Docker compose s NVIDIA_VISIBLE_DEVICES sa dynamicky mení.

Pre nás: oba GPU využité efektívne. Pre iných: automatické škálovanie AI podľa load.

Zero-Knowledge Telemetry

Differential privacy — každá metrika má pridaný noise (Laplace mechanism). $avg_latency = real_avg + noise(\epsilon=0.1)$. Trend je viditeľný, konkrétne hodnoty nie. Lokálny Grafana bez privacy leaku. Optional: --telemetry=strict vypne aj ZK.

Pre nás: vieme ako systém funguje bez leaku. Pre iných: first privacy-preserving telemetry OS.

ScaRgeN Visions 11-15

5 nových vízií — rozšírenie smerom k **multi-modal AI**, **decentralizovanej autonómii**, a **učiacej sa infraštruktúre**.

Autonomous Agent Orchestrator (AAO)

Meta-agent ktorý koordinuje ostatných agentov (Hermes, OpenCode, Jarvis). AAO má prístup ku všetkým systémovým metrikám a dokáže sám rozhodnúť: "GPU je voľné, spustím background fine-tuning", alebo "Ollama pomalá, prepni na BeeLLama". Agenti komunikujú cez **MCP (Model Context Protocol)** — štandardizovaný tool-calling. AAO učí sa z úspešných akcií a vytvára runbooky pre budúce situácie.

Pre nás: OS sa sám optimalizuje bez zásahu. Pre iných: first self-managing AI infrastructure — ako Kubernetes operator alebo pre domáci AI stack.

Multi-Modal Pipeline Studio

Vizuálny drag-and-drop editor pre AI pipeline (podobne ako ComfyUI ale pre celý stack). Spoj SGLang (text) + ComfyUI (image) + MusicGen (audio) + Whisper (STT) do jedného workflow. "Nahraj fotku → AI popíše → vygeneruj hudbu na základe popisu → TTS prečíta". Pipeline sa ukladá ako **DAG (Directed Acyclic Graph)** — možno zdieľať ako "recepty". Verzovanie pipeline ako git.

Pre nás: komplexné multi-modal workflows bez kódovania. Pre iných: first visual AI pipeline OS — creator-friendly.

Adaptive Resource Governor (ARG)

AI-driven resource allocation ktorý sa učí z usage patternov. ARG vie: "po večeri rodina pozerá film → CPU na Jellyfin, GPU idle na background training". "Ráno coding session → GPU na vLLM, CPU na indexovanie". Reinforcement learning model (PPO) na CPU ktorý optimalizuje **QoS (Quality of Service)** pre každého používateľa. Automaticky nastavuje cgroups, Docker resource limits, GPU affinity.

Pre nás: systém sa prispôsobí denným rutinám. Pre iných: first OS ktorý sám riadi zdroje podľa toho kto ho používa.

Decentralized Model Marketplace

P2P model sharing cez IPFS/WebTorrent — komunita SCARLIX používateľov zdieľa fine-tuned modely bez centrálného hubu. "Natrénoval som model na slovenské recipes — zdieľam ako SCARLIX pack". Model integrity overená cez **content addressing (CIDs)** + podpisy. Stiahnutie modelu = automatické healthcheck + benchmark + integrácia do NMR. žiadny App Store, žiadny vendor lock-in.

Pre nás: slovenská AI komunita môže zdieľať models. Pre iných: first decentralized AI model ecosystem — ako Homebrew ale pre AI.

Predictive Maintenance Engine

ML model ktorý predpovedá systémové problémy skôr ako nastanú. Analyzuje: GPU teplotu trend, VRAM fragmentáciu, disk I/O latency, Docker container restart count, SGLang TTFT degradation. "GPU temp stúpa 2°C/hod + VRAM 92% → OOM za ~4 hodiny". Automaticky: zníži max_running_requests, upozorní používateľa, pripraví BeeLlama fallback. **Time-series forecasting** (Prophet alebo LSTM) na historických metrikách.

Pre nás: problémy riešené skôr ako nastanú. Pre iných: first predictive home server OS — ako Tesla preventative maintenance ale pre AI.

Implementation Roadmap

FÁZA	VÍZIE	TIMELINE
v20.0	#5 Voice Shell + #6 Self-Healing + #8 Edge Cache	2026 Q2
v21.0	#1 Kernel Scheduler + #2 Neural Router + #9 GPU Fabric	2026 Q4
v22.0	#11 AAO + #12 Pipeline Studio + #15 Predictive	2027 Q2
v23.0	#3 FHE + #7 Quantum-Safe + #13 ARG	2027 Q4
v24.0	#4 Federated Mesh + #10 ZK Telemetry + #14 Marketplace	2028 Q2

ScaRgeN Manifesto: ScaRgeN nie je len ďalšia verzia SCARLIX OS. Je to **prvý OS navrhnutý od základov pre AI** — AI nie je aplikácia, je vrstva ako networking alebo filesystem. Privacy je default. Self-healing je štandard. Voice je first-class. Quantum-ready.

ScaRgeN

Scar + Generation — nová generácia AI-native OS.

v20.0 target: 2026 Q2.

Začneme s Voice Shell, Self-Healing Snapshots, a Edge AI
Cache.